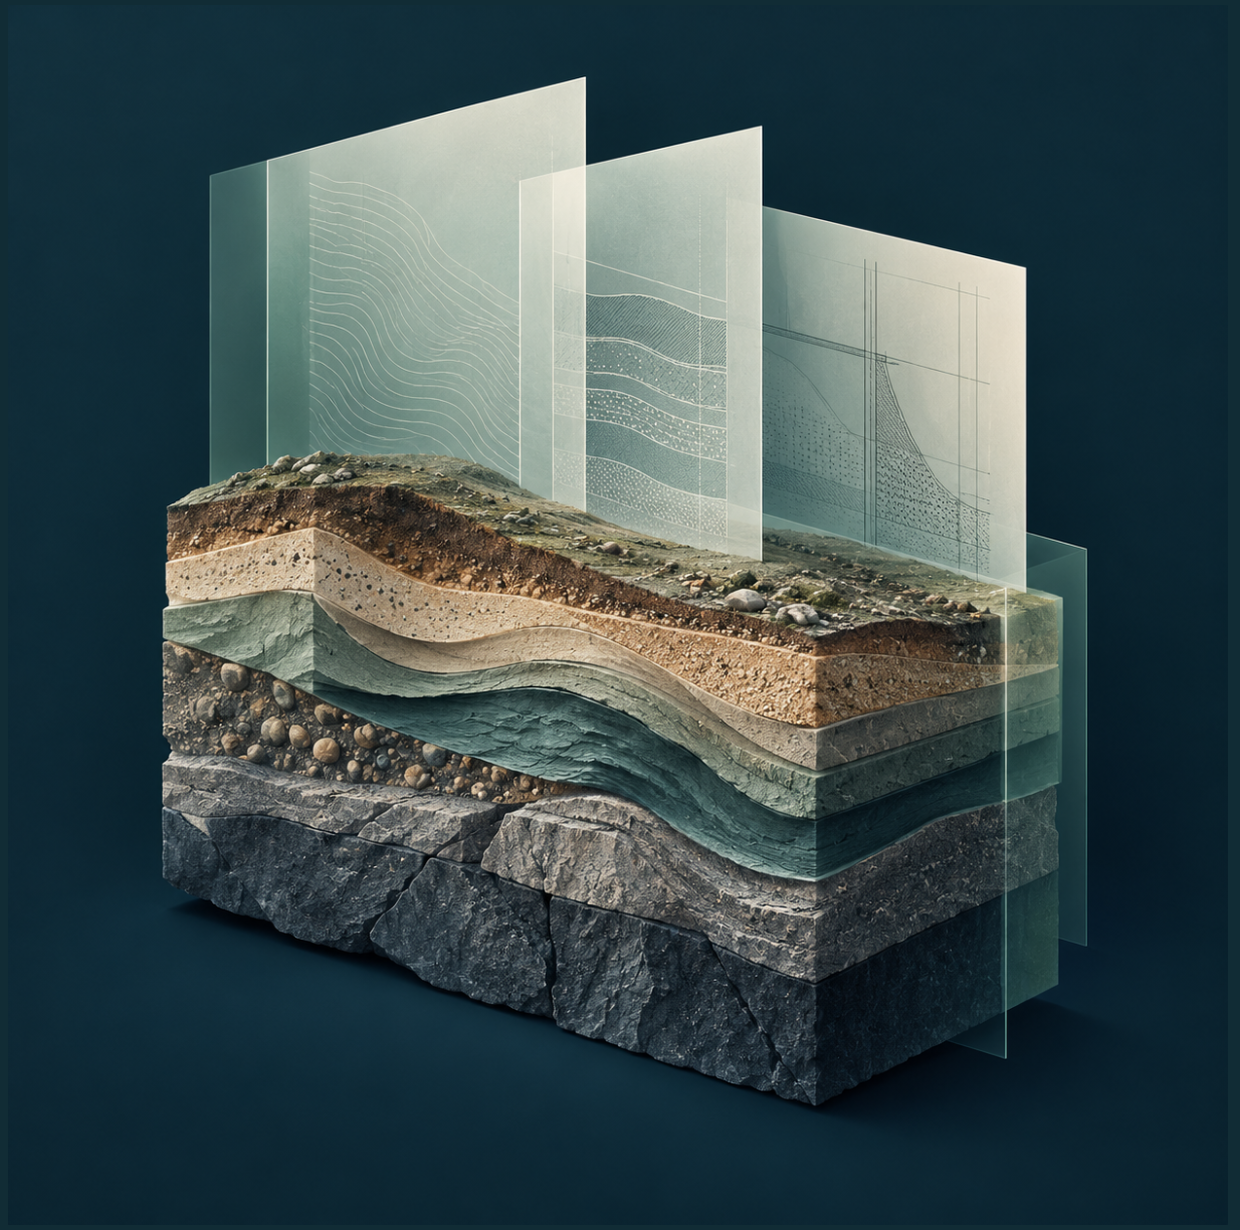
Support Copilot

ИИ-ассистент технической поддержки MIDAS



Дипломный проект
21 октября 2026 года

Задача и рабочий сценарий

Проверяемый ответ по мануалам в привычном интерфейсе инженера

01

Вопрос

Продукт, задача и контекст обращения

02

Поиск

Фрагменты мануалов с происхождением

03

Ответ

Пояснение, цитаты и оригиналы

04

Решение

Проверка инженером и согласие на отправку

Инженер сохраняет контроль над фактами и внешними действиями

Корпус и происхождение данных

10

канонических источников

9 PDF и 1 CHM
GTS NX и Civil

14 139

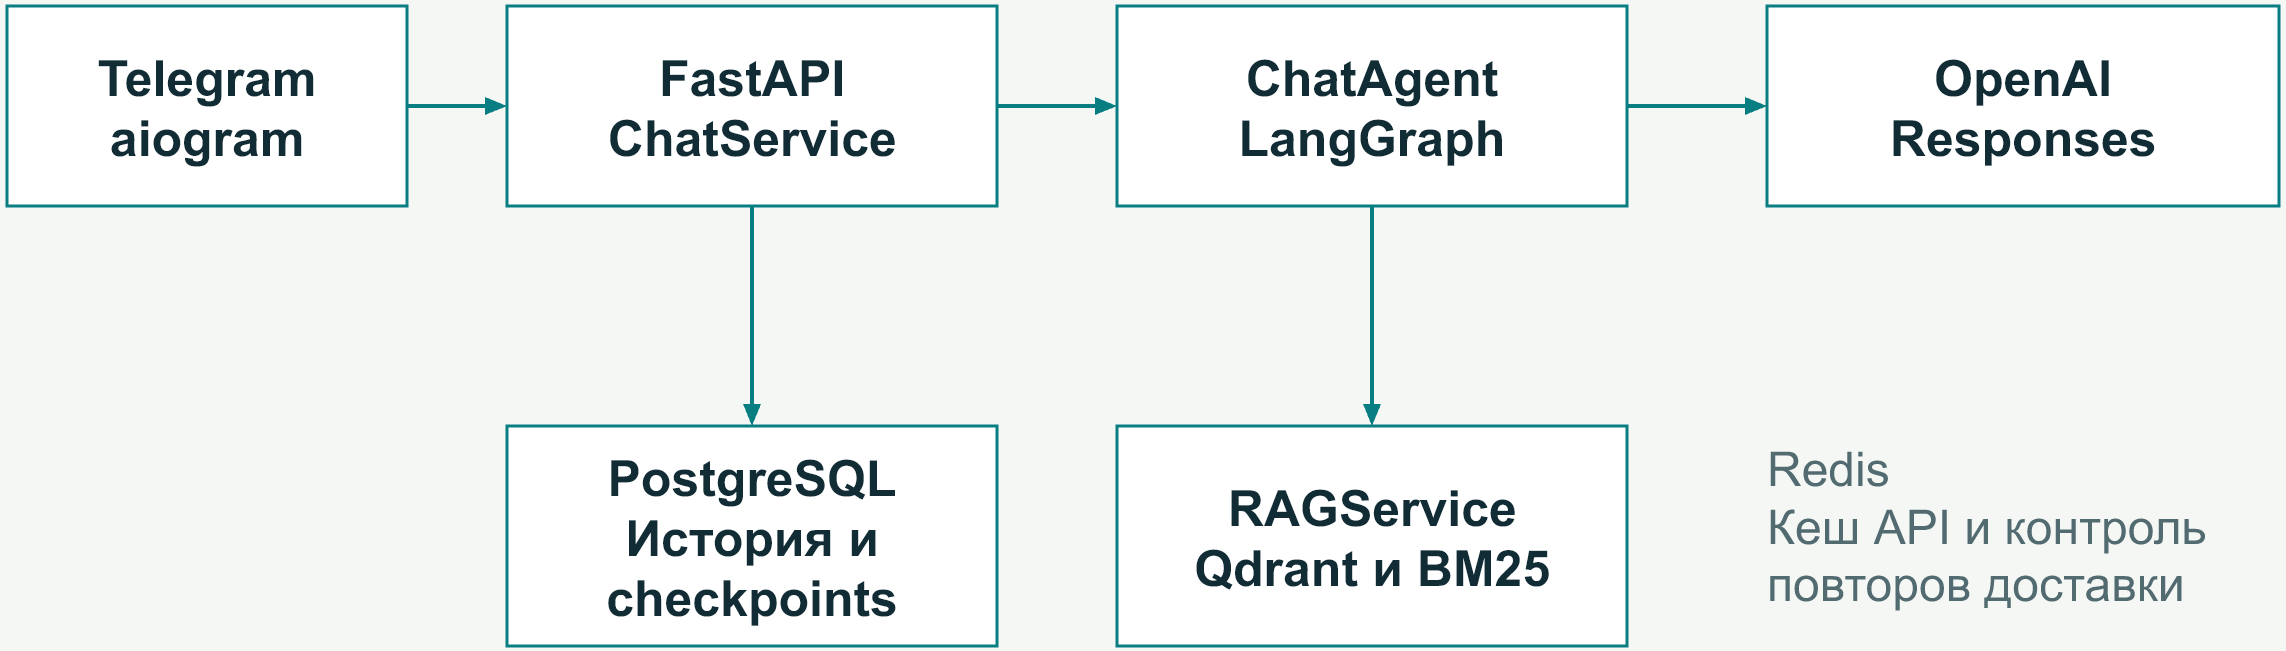
векторов в Qdrant

60 HTML-зеркал исключены
Источник и ревизия сохраняются

Страница PDF или CHM topic сопровождают найденный фрагмент

Архитектура принятой версии

Интерфейс, прикладной сценарий и инфраструктура разделены



Checkpoints сохраняют позицию исполнения и ожидание подтверждения

Технологии и их роли

Слой	Технологии	Ответственность
Интерфейс	aiogram, HTTPX	Telegram и вызовы backend
API	FastAPI, Pydantic	Контракты и проверка входа
Агент	LangGraph, OpenAI SDK	Состояние, tools и генерация
Поиск	LlamaIndex, Qdrant, BM25	Индексация и retrieval
Хранение	PostgreSQL, Redis	История, checkpoints и доставка
Поставка	Python 3.13, uv, Docker	Окружение и сборка

Phoenix tracing и локальный reranker остаются опциональными

Выбор модели генерации

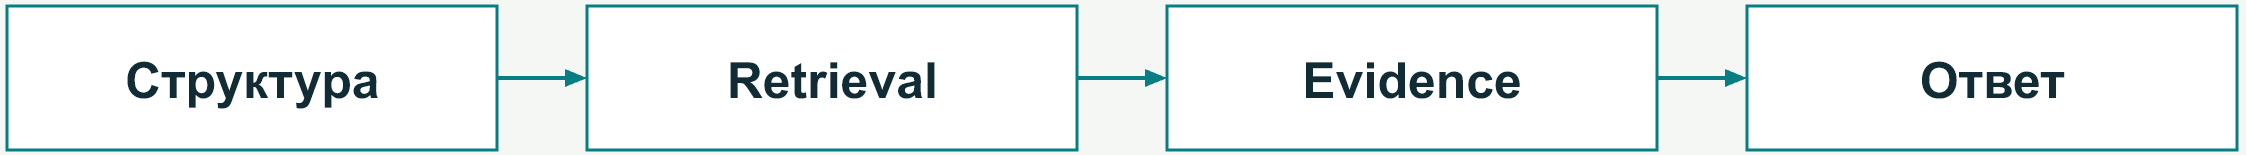
gpt-6-luna / Responses / medium / priority

Вариант	Средняя полнота	Генерация, USD
mini	0,906	0,24594
Luna low	0,875	0,02872
Luna medium	0,906	0,04109

Medium сохранил полноту mini при меньшем расходе генерации

Опыт 15.10.2026: Standard, 48 ответов на вариант; сейчас — Priority
Историческая стоимость без embeddings и condense

Поиск и подготовка доказательств



Страницы, таблицы и происхождение

Dense и BM25 с объединением рангов

Текст фрагментов и ограничения

Цитаты и доступ к оригиналу

large / 1024d

Embeddings
Cosine

1024 / 64

Chunk и overlap в токенах

top-k 10

Reranker выключен

12 000 + до 6000 символов подготовленного evidence

Один агент и подтверждение действий

Общий контекст вопроса и поиска

+33,63%

токенов у multi-agent

+77,36%

p50 задержки в учебном опыте

5 вопросов, одна общая mock-KB

Контроль внешней отправки

01 Адресат и полный текст

02 Сохранённый draft и пауза

03 Подтверждение или отмена

Согласие связано с владельцем и UUID конкретного черновика

Состояние и обработка сбоев

40

учебных чатов сохранились после рестарта

Совпали сообщения и хэши истории

Контекст

История и checkpoints

Доступ

Владелец и блокировка чата

Deadlines

60 с generation / 90 с turn

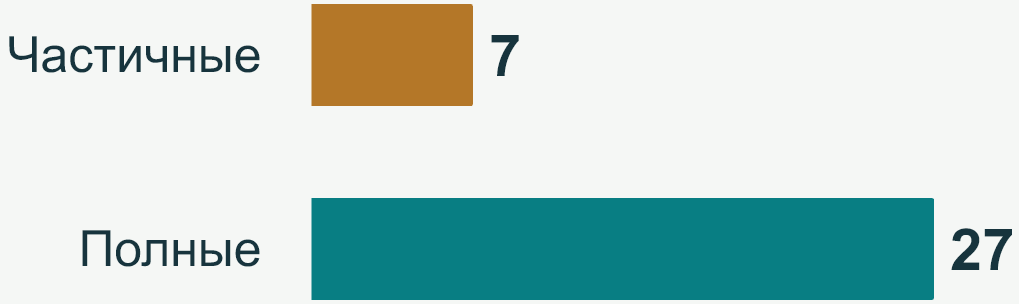
Доставка

Unknown требует сверки

Эксплуатационная граница: один API worker и раздельные транзакции

Фактические результаты проверок

34 эталонных ответа



1522 PASS / 12 skip

Offline suite

25 PostgreSQL PASS

Отдельная одноразовая БД

154 использования источников

HTTP wall time

7,63 с медиана

14,27 с p95

43 сценария + 5 расширений до исправления уточнения. Затем: offline и focused regression.
HTTP-замер не измеряет доставку Telegram и не подтверждает SLA.

Итог и границы применения

Рабочий помощник инженера с проверяемыми источниками

Ограничения принятой версии

Частичные ответы по DOF и Mohr–Coulomb
Формулы и изображения требуют доизвлечения
Research gate и SLA остаются открытыми

Пользователь проверил Telegram и принял результат